

PCA 与 SVD 关系的证明

1 问题设定

设数据矩阵为

$$X \in \mathbb{R}^{N \times D},$$

其中 N 表示样本数, D 表示原始特征维度。

PCA 的目标是把数据从 D 维降到 L 维, 其中

$$L < D.$$

设投影矩阵为

$$V \in \mathbb{R}^{D \times L},$$

并要求 V 的列向量两两正交且归一, 即

$$V^T V = I_L.$$

PCA 的重构为

$$X V V^T.$$

因此 PCA 可以写成最小化重构误差的问题:

$$\min_{V^T V = I_L} \|X - X V V^T\|_F^2.$$

下面证明这个问题等价于最大化

$$\text{tr}(V^T X^T X V).$$

2 最小化重构误差等价于最大化投影方差

由 Frobenius 范数和 trace 的关系:

$$\|A\|_F^2 = \text{tr}(A^T A),$$

可得

$$\|X - X V V^T\|_F^2 = \text{tr}((X - X V V^T)^T (X - X V V^T)).$$

因为

$$(X - XVV^T)^T = X^T - VV^T X^T,$$

所以

$$\begin{aligned}\|X - XVV^T\|_F^2 &= \text{tr}((X^T - VV^T X^T)(X - XVV^T)) \\ &= \text{tr}(X^T X - X^T XVV^T - VV^T X^T X + VV^T X^T XVV^T).\end{aligned}$$

由 trace 的线性性：

$$\|X - XVV^T\|_F^2 = \text{tr}(X^T X) - \text{tr}(X^T XVV^T) - \text{tr}(VV^T X^T X) + \text{tr}(VV^T X^T XVV^T).$$

下面逐项化简。

首先，由 trace 的循环不变性，

$$\text{tr}(X^T XVV^T) = \text{tr}(V^T X^T XV).$$

同理，

$$\text{tr}(VV^T X^T X) = \text{tr}(V^T X^T XV).$$

对于最后一项：

$$\begin{aligned}\text{tr}(VV^T X^T XVV^T) &= \text{tr}(V^T VV^T X^T XV) \\ &= \text{tr}(I_L V^T X^T XV) \\ &= \text{tr}(V^T X^T XV).\end{aligned}$$

因此

$$\begin{aligned}\|X - XVV^T\|_F^2 &= \text{tr}(X^T X) - \text{tr}(V^T X^T XV) - \text{tr}(V^T X^T XV) + \text{tr}(V^T X^T XV) \\ &= \text{tr}(X^T X) - \text{tr}(V^T X^T XV).\end{aligned}$$

由于

$$\text{tr}(X^T X)$$

与 V 无关，所以

$$\min_{V^T V = I_L} \|X - XVV^T\|_F^2$$

等价于

$$\max_{V^T V = I_L} \text{tr}(V^T X^T XV).$$

因此，PCA 问题可以转化为

$$\boxed{\max_{V \in \mathbb{R}^{D \times L}, V^T V = I_L} \text{tr}(V^T X^T XV)}.$$

3 对 $X^T X$ 做特征值分解

令

$$C = X^T X.$$

因为 C 是实对称半正定矩阵，所以可以正交对角化：

$$C = V_c \Lambda V_c^T,$$

其中

$$V_c \in \mathbb{R}^{D \times D}, \quad V_c^T V_c = V_c V_c^T = I_D,$$

并且

$$\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_D).$$

由于 $C = X^T X$ 是半正定矩阵，所以

$$\lambda_i \geq 0.$$

不妨令特征值按从大到小排列：

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D \geq 0.$$

于是

$$\begin{aligned} V^T X^T X V &= V^T C V \\ &= V^T V_c \Lambda V_c^T V. \end{aligned}$$

令

$$W = V_c^T V.$$

因为

$$V_c \in \mathbb{R}^{D \times D}, \quad V \in \mathbb{R}^{D \times L},$$

所以

$$W \in \mathbb{R}^{D \times L}.$$

并且

$$\begin{aligned} W^T W &= (V_c^T V)^T (V_c^T V) \\ &= V^T V_c V_c^T V \\ &= V^T I_D V \\ &= V^T V \\ &= I_L. \end{aligned}$$

所以 W 也是列正交矩阵。

于是

$$\text{tr}(V^T X^T X V) = \text{tr}(W^T \Lambda W).$$

因此原问题等价于

$$\max_{W \in \mathbb{R}^{D \times L}, W^T W = I_L} \text{tr}(W^T \Lambda W).$$

4 展开 $\text{tr}(W^T \Lambda W)$

设

$$W = \begin{bmatrix} w_1^T \\ w_2^T \\ \vdots \\ w_D^T \end{bmatrix},$$

其中 w_i^T 表示 W 的第 i 行。

因此

$$w_i \in \mathbb{R}^L.$$

因为

$$\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_D),$$

所以

$$\Lambda W = \begin{bmatrix} \lambda_1 w_1^T \\ \lambda_2 w_2^T \\ \vdots \\ \lambda_D w_D^T \end{bmatrix}.$$

于是

$$W^T \Lambda W = \sum_{i=1}^D \lambda_i w_i w_i^T.$$

因此

$$\begin{aligned} \text{tr}(W^T \Lambda W) &= \text{tr} \left(\sum_{i=1}^D \lambda_i w_i w_i^T \right) \\ &= \sum_{i=1}^D \lambda_i \text{tr}(w_i w_i^T). \end{aligned}$$

因为

$$\text{tr}(w_i w_i^T) = w_i^T w_i = \|w_i\|_2^2,$$

所以

$$\text{tr}(W^T \Lambda W) = \sum_{i=1}^D \lambda_i \|w_i\|_2^2.$$

令

$$a_i = \|w_i\|_2^2.$$

则目标函数变为

$$\sum_{i=1}^D \lambda_i a_i.$$

下面分析 a_i 的约束。

因为

$$W^T W = I_L,$$

所以

$$\begin{aligned} \sum_{i=1}^D a_i &= \sum_{i=1}^D \|w_i\|_2^2 \\ &= \text{tr}(W^T W) \\ &= \text{tr}(I_L) \\ &= L. \end{aligned}$$

同时, 由于 W 是列正交矩阵, 所以

$$W W^T$$

是一个正交投影矩阵。

它的第 i 个对角元为

$$(W W^T)_{ii} = w_i^T w_i = \|w_i\|_2^2 = a_i.$$

正交投影矩阵的对角元满足

$$0 \leq (W W^T)_{ii} \leq 1.$$

所以

$$0 \leq a_i \leq 1.$$

于是问题变成

$$\max \sum_{i=1}^D \lambda_i a_i,$$

其中

$$\sum_{i=1}^D a_i = L, \quad 0 \leq a_i \leq 1.$$

由于

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_D,$$

为了使

$$\sum_{i=1}^D \lambda_i a_i$$

最大, 就应该把权重 a_i 尽量放到最大的前 L 个特征值上。

因此最优情况为

$$a_1 = a_2 = \cdots = a_L = 1, \quad a_{L+1} = a_{L+2} = \cdots = a_D = 0.$$

此时最大值为

$$\sum_{i=1}^L \lambda_i.$$

5 最优 W 的形式

由

$$a_i = \|w_i\|_2^2$$

可知：

当

$$a_{L+1} = \cdots = a_D = 0$$

时，说明

$$w_{L+1} = w_{L+2} = \cdots = w_D = 0.$$

也就是说，最优的 W 的后 $D - L$ 行全为零。

同时，因为

$$W^T W = I_L,$$

所以 W 的前 L 行构成的 $L \times L$ 矩阵必须是正交矩阵。

因此，最一般的最优 W 可以写成

$$W = \begin{bmatrix} I_L \\ 0 \end{bmatrix} T,$$

其中

$$T \in \mathbb{R}^{L \times L}, \quad T^T T = I_L.$$

这里的 T 是一个 $L \times L$ 的正交矩阵，表示在前 L 维主子空间内部还可以做任意正交旋转。

因为

$$W = V_c^T V,$$

所以

$$V = V_c W.$$

代入 W 的最一般形式：

$$V = V_c \begin{bmatrix} I_L \\ 0 \end{bmatrix} T.$$

而

$$V_c \begin{bmatrix} I_L \\ 0 \end{bmatrix} = V_c[:, 1:L].$$

所以

$$V = V_c[:, 1:L] T.$$

因此，PCA 最优投影矩阵的一般形式为

$$\boxed{V = V_c[:, 1:L] T, \quad T^T T = I_L.}$$

这说明 PCA 真正确定的是由 $X^T X$ 的前 L 个最大特征值对应特征向量张成的子空间，而不是某一个唯一的正交基。

如果取

$$T = I_L,$$

那么得到一个常用代表解：

$$V = V_c[:, 1 : L].$$

6 与 SVD 的关系

设 X 的奇异值分解为

$$X = U \Sigma S^T.$$

其中

$$U^T U = I, \quad S^T S = I.$$

于是

$$\begin{aligned} X^T X &= (U \Sigma S^T)^T (U \Sigma S^T) \\ &= S \Sigma^T U^T U \Sigma S^T. \end{aligned}$$

因为

$$U^T U = I,$$

所以

$$X^T X = S \Sigma^T \Sigma S^T.$$

令

$$\Lambda = \Sigma^T \Sigma.$$

由于 $\Sigma^T \Sigma$ 是对角矩阵，其对角元是奇异值的平方，所以

$$\Lambda = \text{diag}(\sigma_1^2, \sigma_2^2, \dots, \sigma_D^2).$$

因此

$$X^T X = S \Lambda S^T.$$

这正是 $X^T X$ 的特征值分解。

所以 $X^T X$ 的特征向量矩阵就是 SVD 中的右奇异向量矩阵：

$$V_c = S.$$

并且

$$\lambda_i = \sigma_i^2.$$

由前面已经证明的结论：

$$V = V_c[:, 1 : L]T,$$

可得

$$\boxed{V = S[:, 1 : L]T, \quad T^T T = I_L.}$$

也就是说，PCA 选择的投影方向，正是 SVD 中前 L 个最大奇异值对应的右奇异向量所张成的子空间。

如果取

$$T = I_L,$$

那么得到常用的标准选择：

$$\boxed{V = S[:, 1 : L].}$$

7 PCA 降维结果与 SVD 的关系

令

$$S_L = S[:, 1 : L].$$

由于最一般地有

$$V = S_L T,$$

所以 PCA 降维后的数据为

$$XV = X S_L T.$$

由 SVD 分解

$$X = U \Sigma S^T,$$

可得

$$X S_L = U \Sigma S^T S_L.$$

因为 S 是正交矩阵，所以

$$S^T S_L = \begin{bmatrix} I_L \\ 0 \end{bmatrix}.$$

因此

$$X S_L = U \Sigma \begin{bmatrix} I_L \\ 0 \end{bmatrix}.$$

$$U \Sigma \begin{bmatrix} I_L \\ 0 \end{bmatrix} = [\sigma_1 u_1, \sigma_2 u_2, \dots, \sigma_L u_L]$$

这相当于只保留前 L 个奇异值和对应的左奇异向量。

记

$$U_L = U[:, 1 : L],$$

并令

$$\Sigma_L = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_L).$$

于是

$$XS_L = U_L \Sigma_L.$$

所以

$$XV = XS_L T = U_L \Sigma_L T.$$

因此, PCA 降维后的结果一般为

$$\boxed{XV = U_L \Sigma_L T.}$$

如果取

$$T = I_L,$$

则得到标准形式:

$$\boxed{XV = U_L \Sigma_L.}$$

8 总结

我们证明了:

$$\min_{V^T V = I_L} \|X - XV V^T\|_F^2$$

等价于

$$\max_{V^T V = I_L} \text{tr}(V^T X^T X V).$$

令

$$C = X^T X = V_c \Lambda V_c^T,$$

其中

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D.$$

则最大化问题的最优投影矩阵一般为

$$\boxed{V = V_c[:, 1 : L] T, \quad T^T T = I_L.}$$

这说明 PCA 选择的是 $X^T X$ 的前 L 个最大特征值对应特征向量张成的子空间。

又因为

$$X = U \Sigma S^T$$

推出

$$X^T X = S \Sigma^T \Sigma S^T,$$

所以

$$V_c = S.$$

因此

$$V = S[:, 1 : L]T, \quad T^T T = I_L.$$

其中 T 是任意 $L \times L$ 正交矩阵, 表示在主成分空间内部的正交旋转。

如果取

$$T = I_L,$$

则得到通常写法:

$$V = S[:, 1 : L].$$

此时 PCA 降维后的数据为

$$XV = U_L \Sigma_L.$$

一般情况下, 则为

$$XV = U_L \Sigma_L T.$$